БУДУЩЕЕ
В НАШИХ
РУКАХ

Введение в дедупликацию

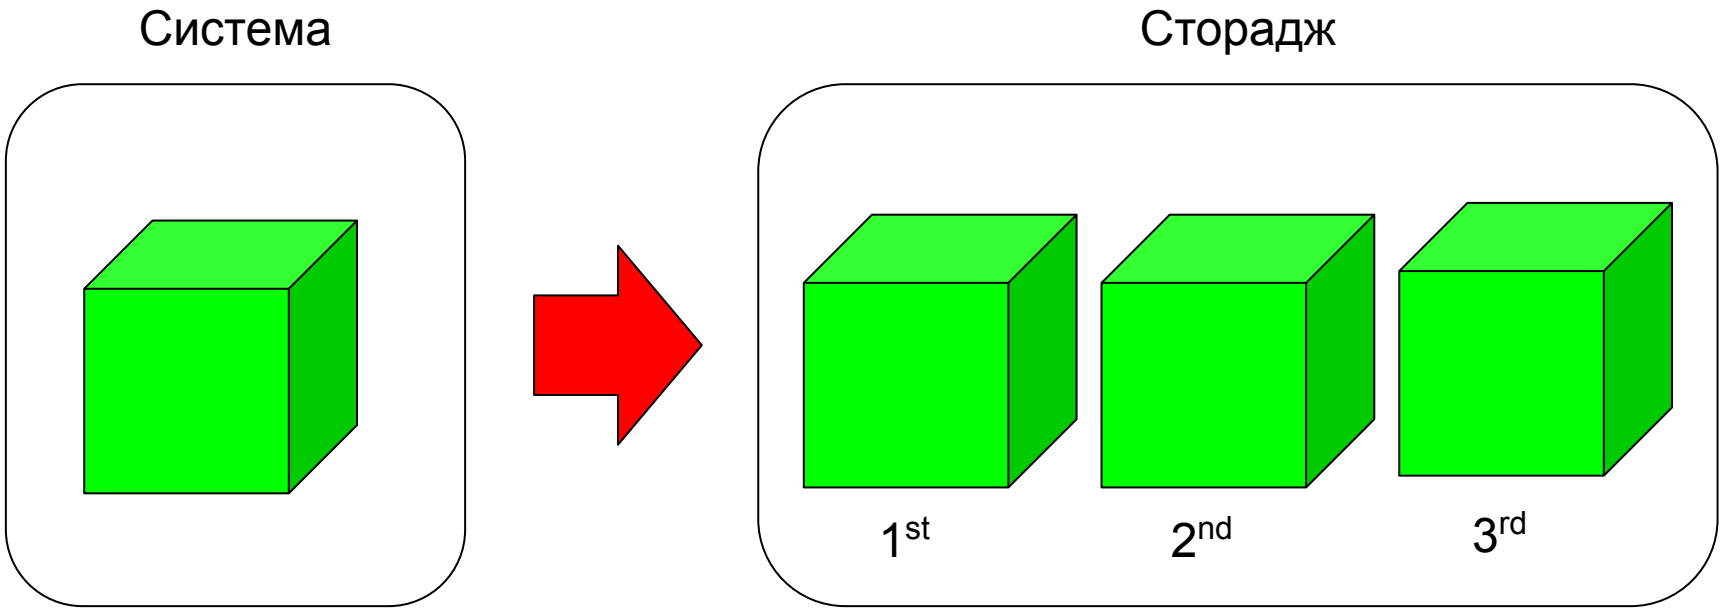
Дмитриевцев Алексей

Бэкап

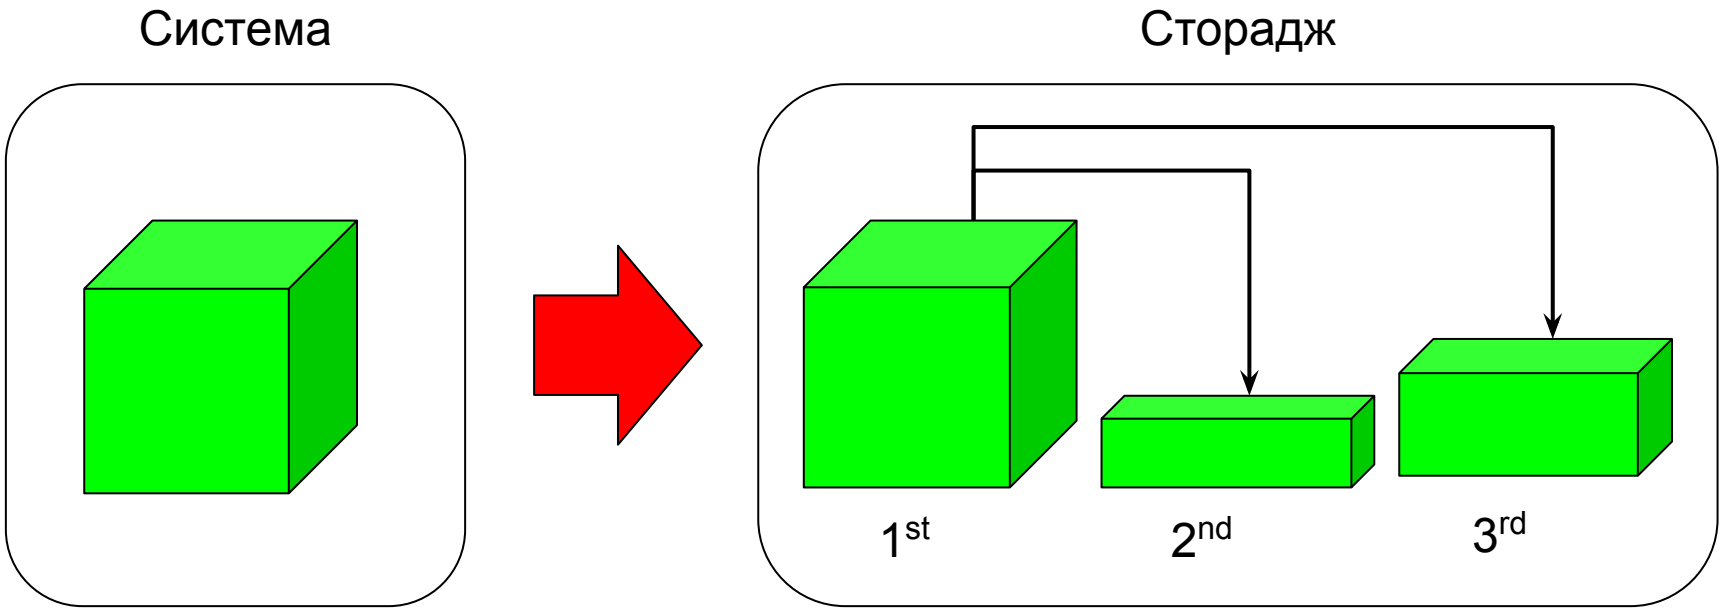
Выделяют виды бэкапов:

- полный
- дифференциальный
- инкрементальный

Полный бэкап

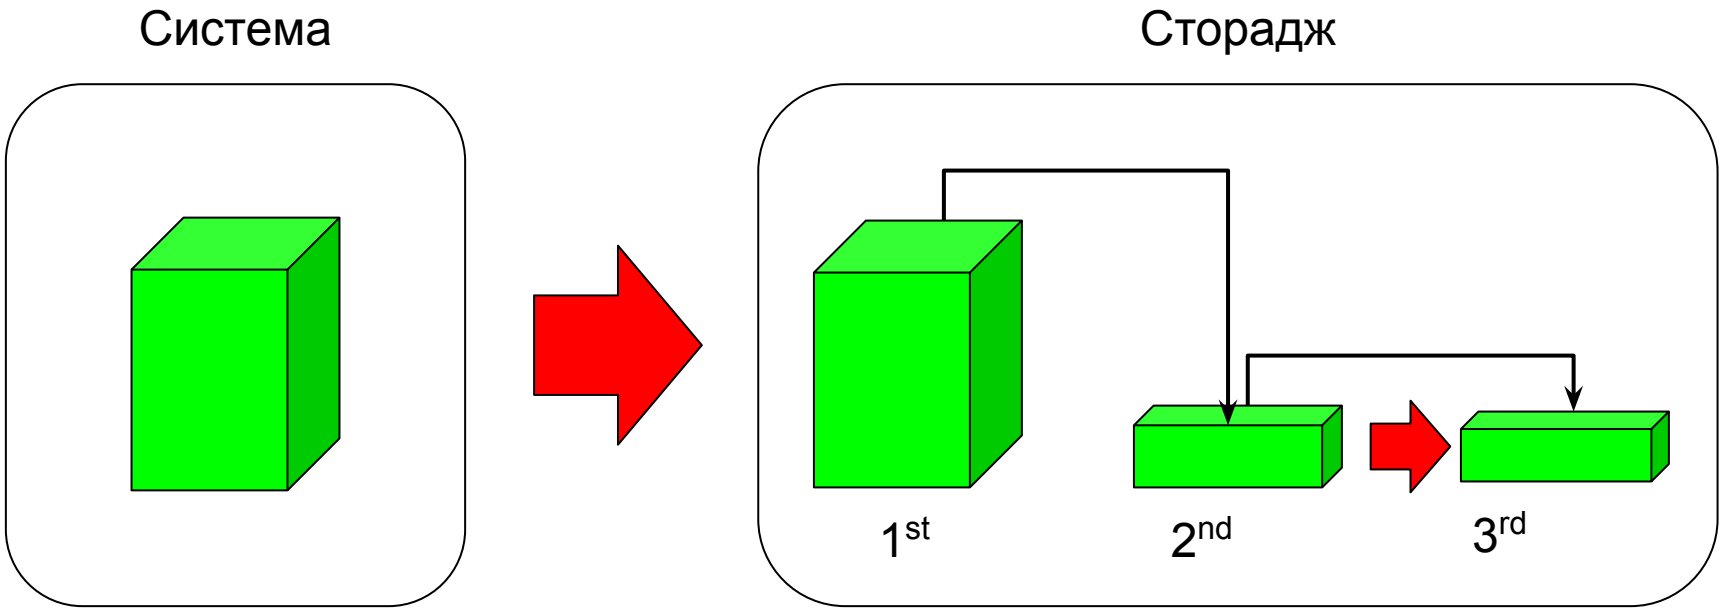


Диф бэкап



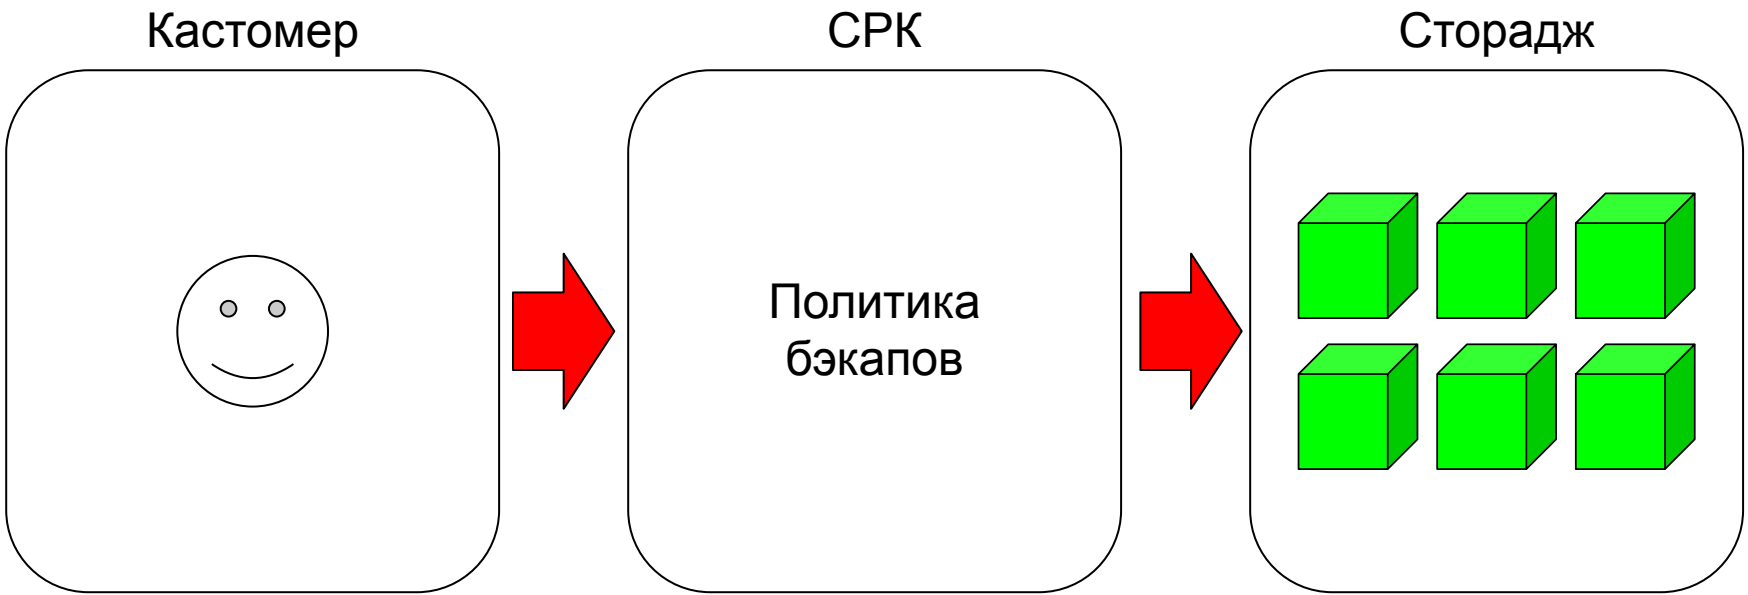
Храним только измененные файлы относительно полного бэкапа

Инкремент



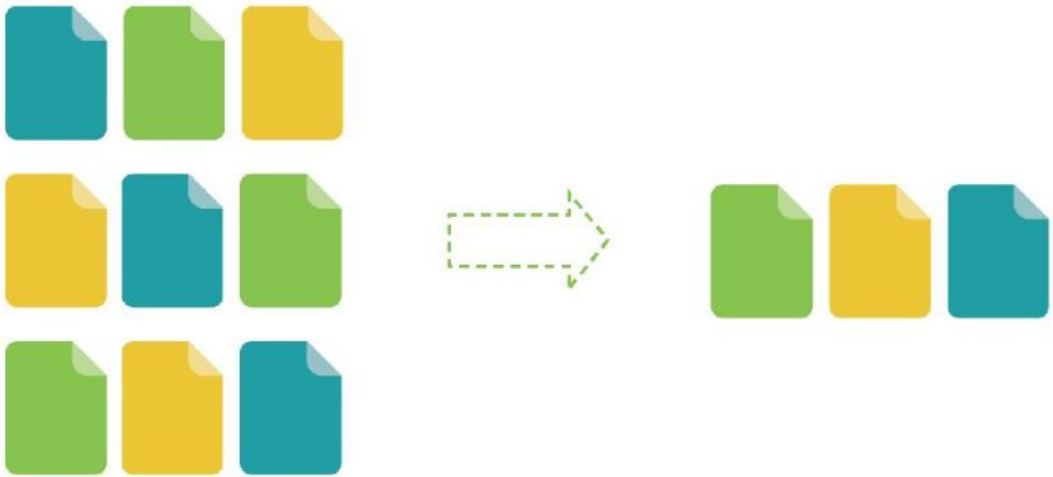
Храним изменения относительного предыдущего бэкапа

Сохранение бэкапа



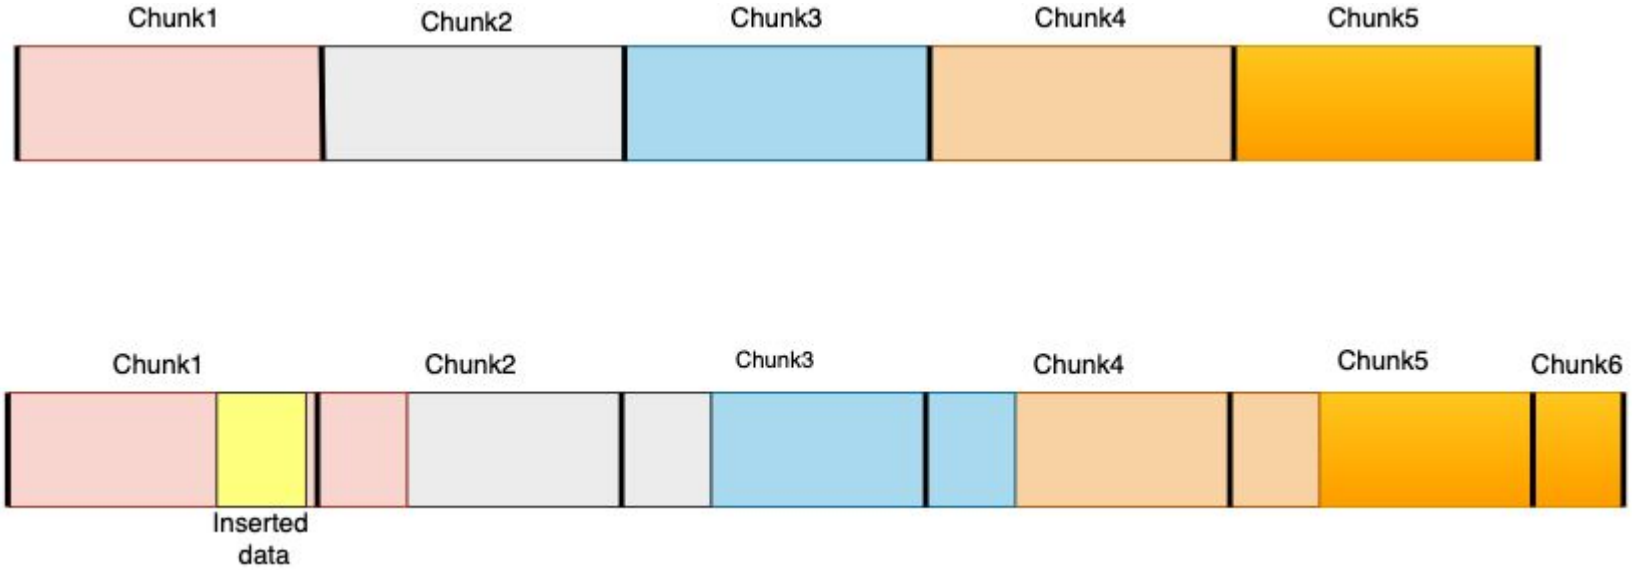
Дедупликация

Дедупликация – подход к хранению данных, позволяющий эффективно хранить большое число **бэкапов на сторадже**



Boundary-shift problem

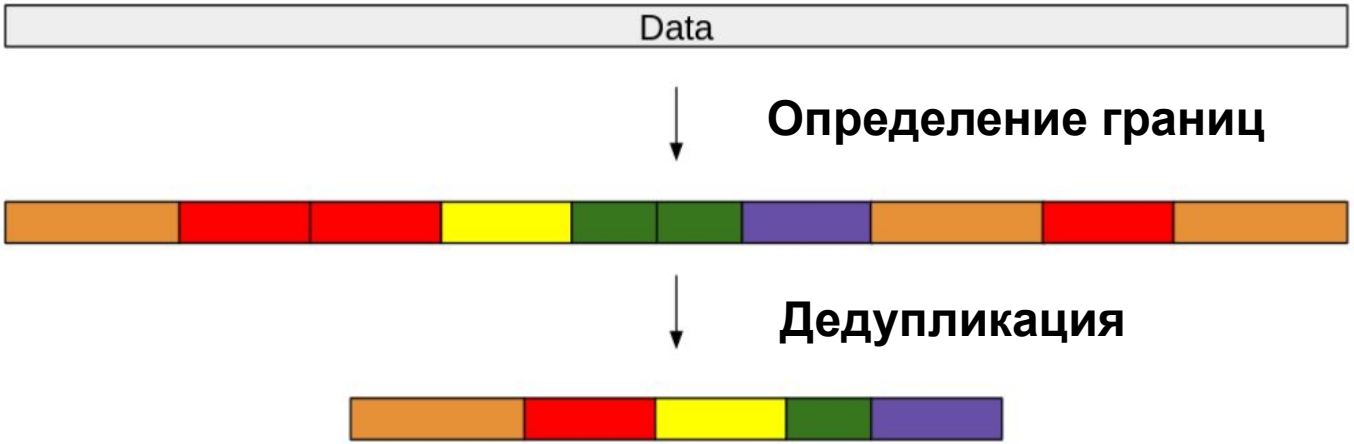
Разбиение на блоки одного размера неэффективно:



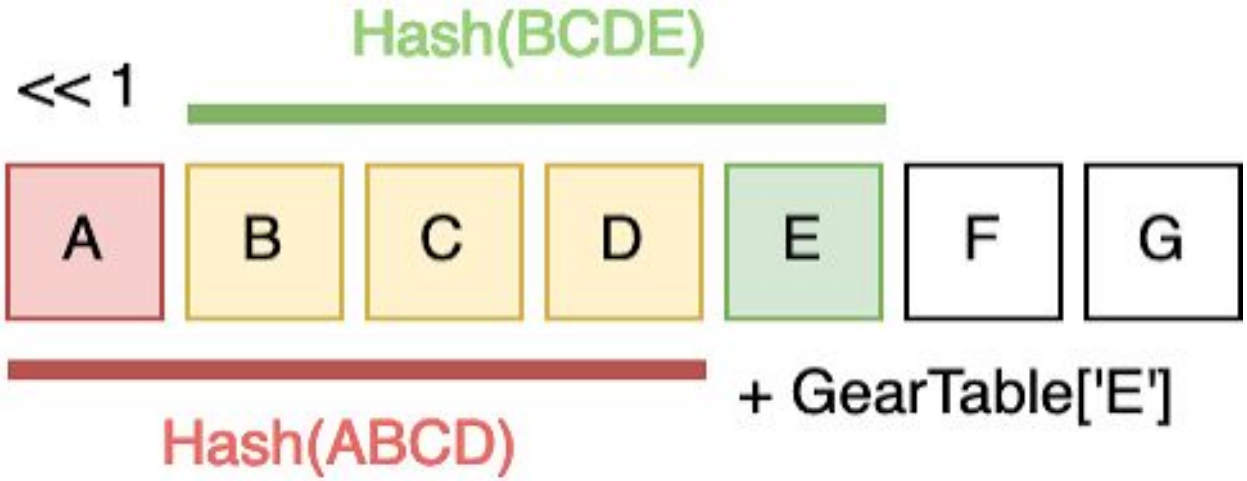
Источник изображения: Jump-Based Backup: An Efficient Data Backup, Alla Levina,Andrei Semenov

Content-Defined Chunking (CDC)

CDC – более современный подход для дедупликации, который выделяет чанки переменного размера с использованием специальных хэшей



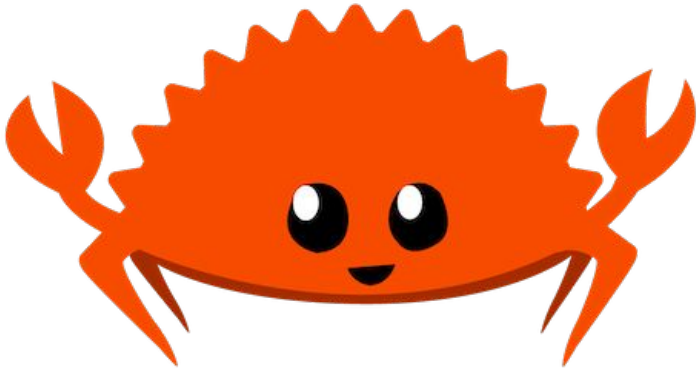
Rolling Hash



ChunkFS

Существует множество алгоритмов CDC:

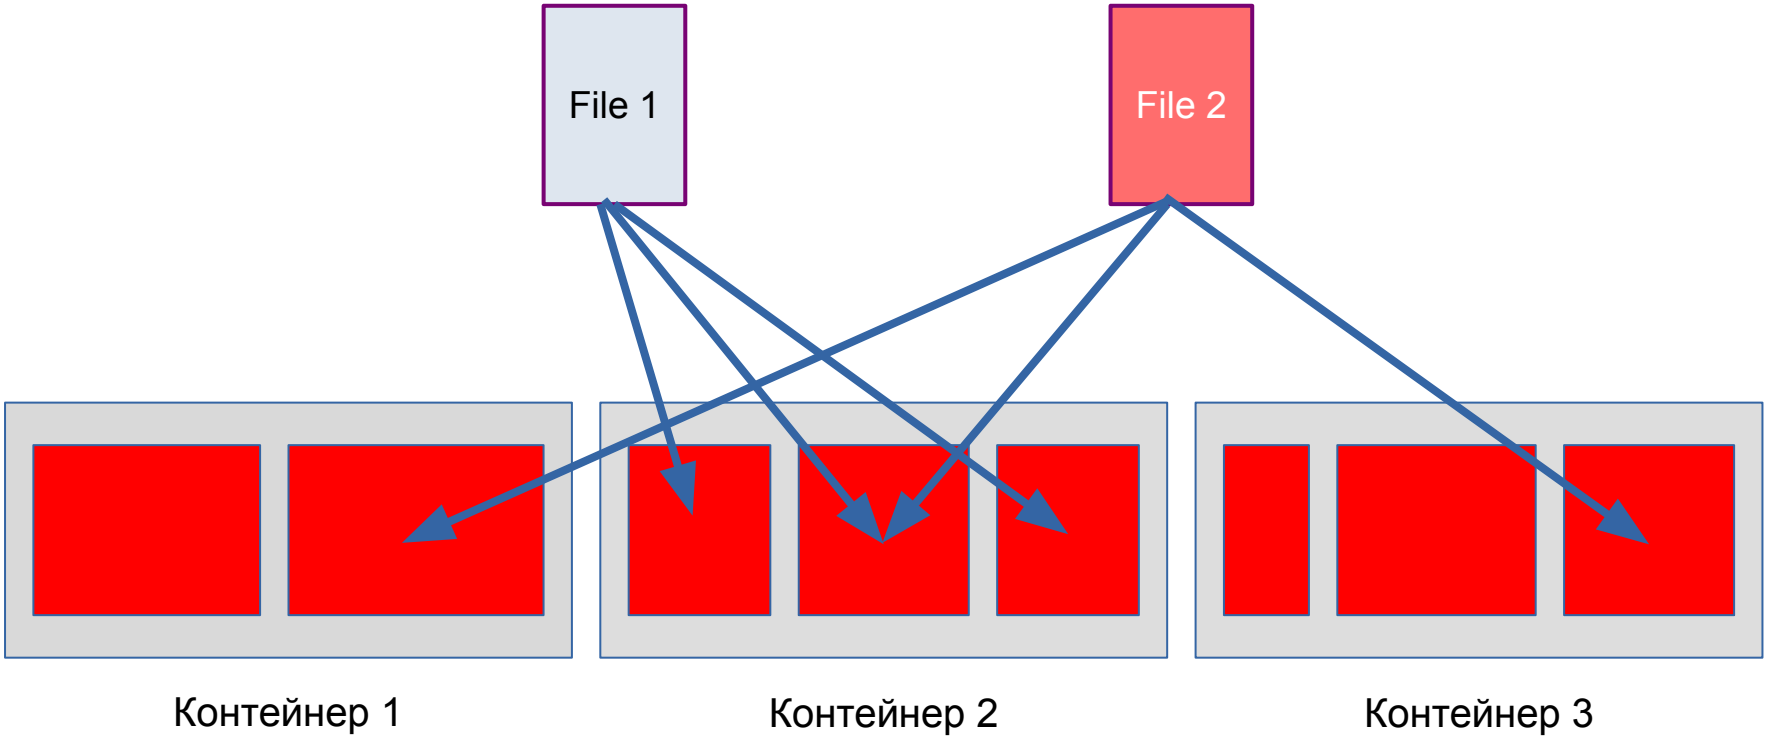
- RabinCDC
- FastCDC
- SuperCDC
- QuickCDC
- ……



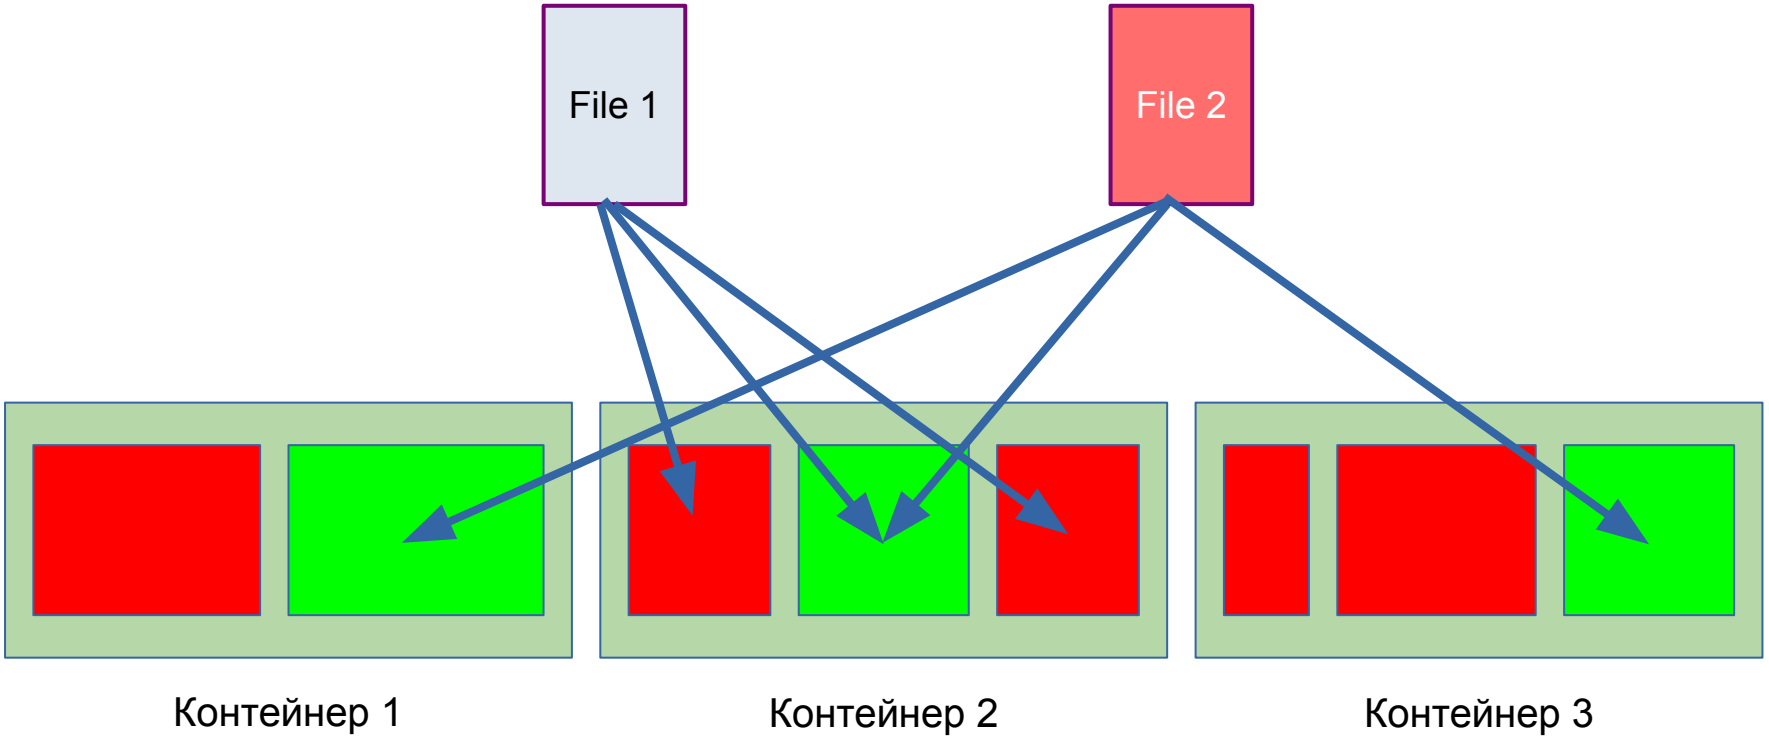
ChunkFS[1] – модельная файловая система, написанная на **Rust**, которая позволяет комплексно сравнивать различные алгоритмы дедупликации

[1] – https://github.com/Piletskii-Oleg/chunkfs

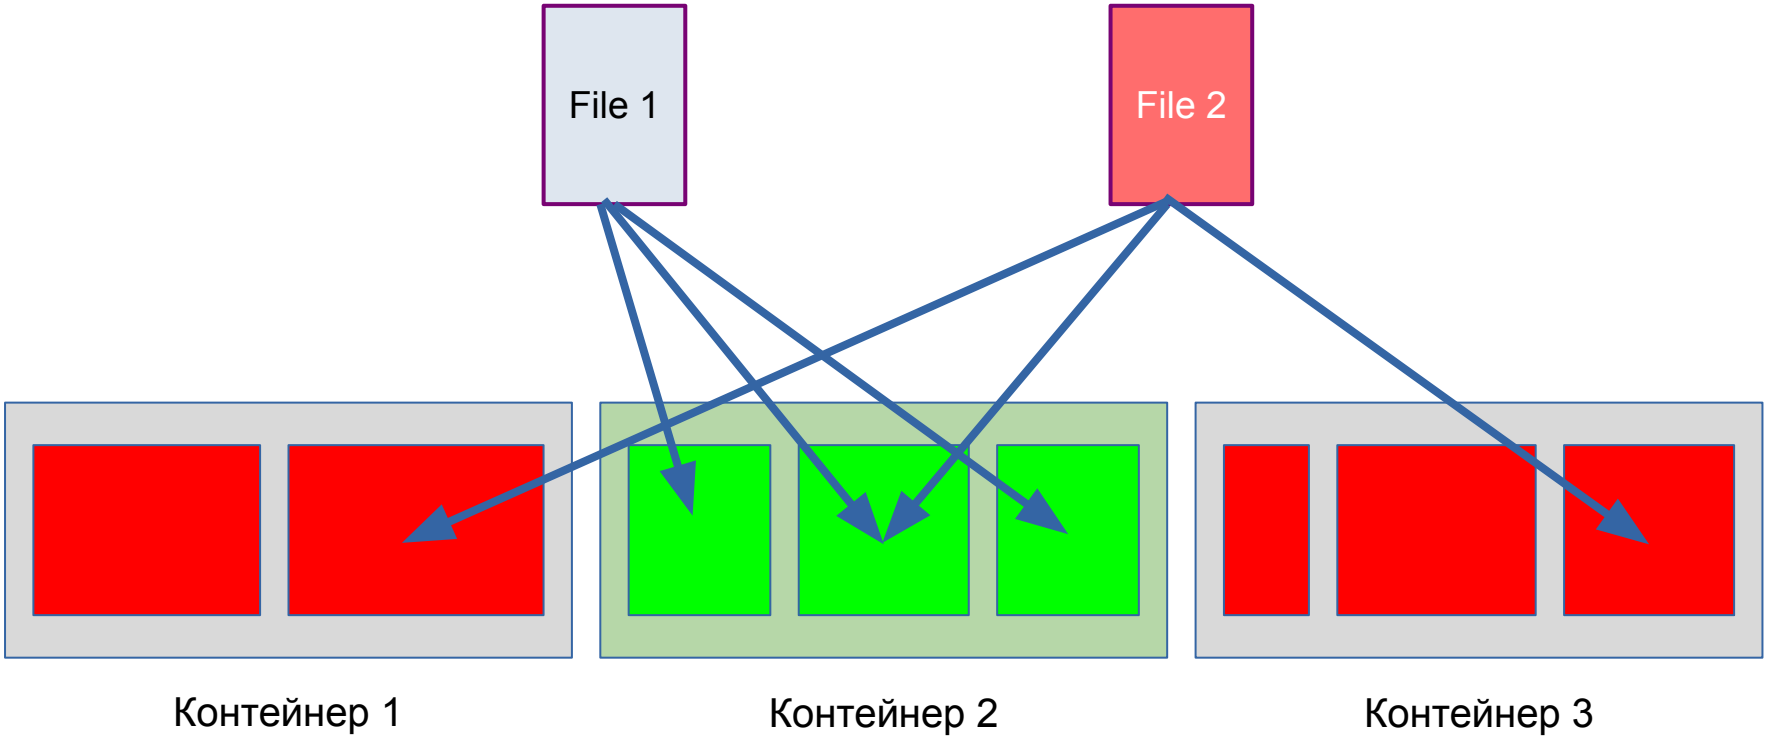
Проблема чтения, контейнеры



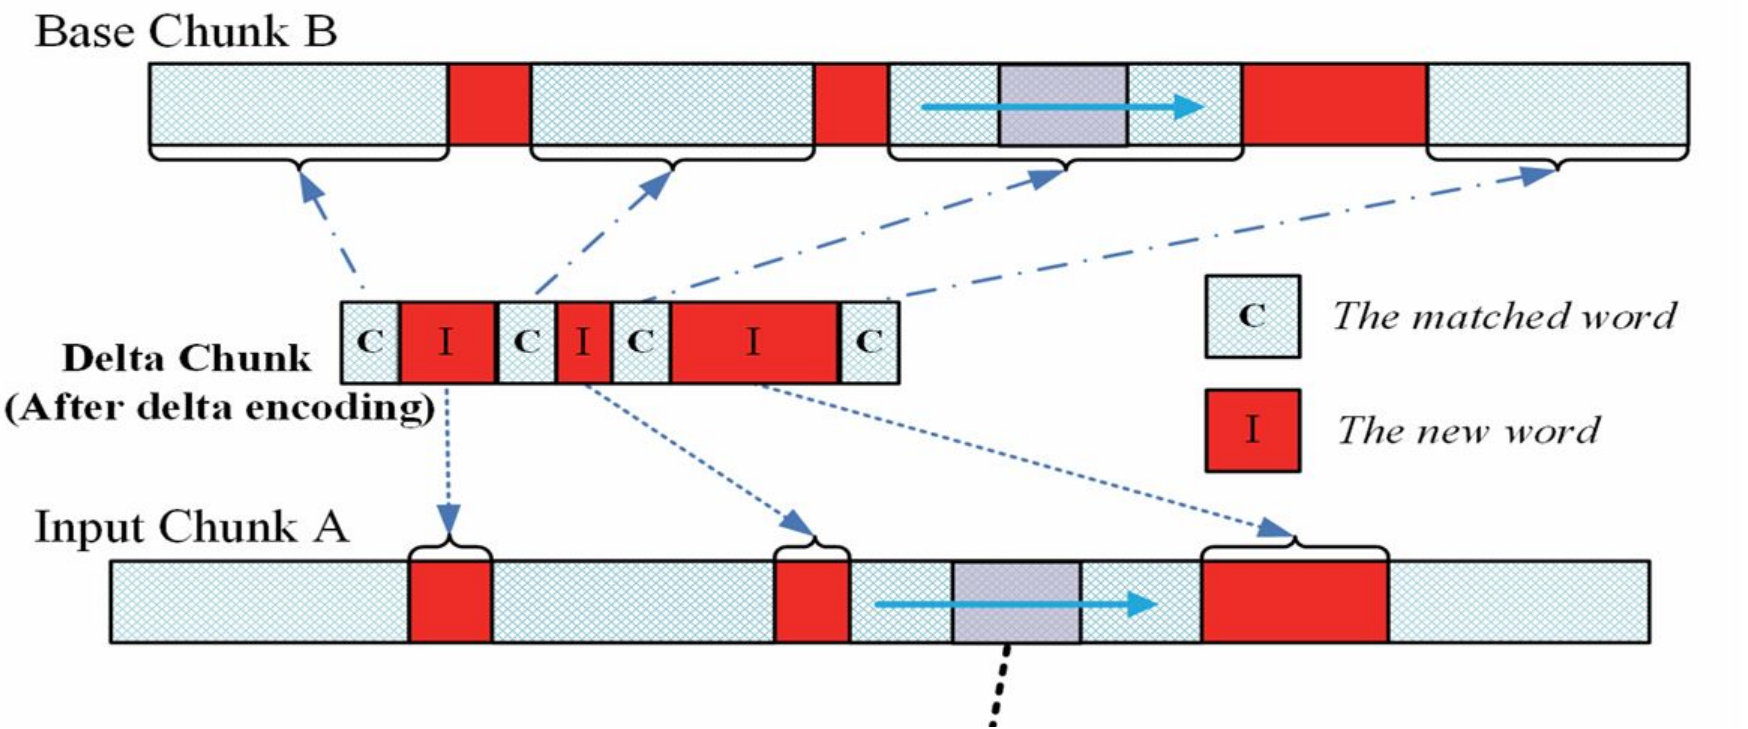
Проблема чтения, контейнеры



Проблема чтения, контейнеры



Дельта-кодирование – новый подход



SBC – новый подход

SBC (Similarity Based Chunking) использует дельта-кодирование и поиск схожих кандидатов для дедупликации

